Multimedijalni računarski sistemi

2. Kompresija podataka

Sadržaj

- Osnove kompresije podataka
- Načini za kompresiju
- Tehnike kompresije
- RL kodovanje
- Korišćenje stabala za generisanje kodova
- Huffmanovo kodovanje

Osnove kompresije podataka

- Motivacija i potreba za kompresijom
 - Veličina fajlova sa podacima velika
 - Nepraktično za skladištenje
 - Nepraktično za prenos
- Kompresija i dekompresija
 - Brzina kompresije
 - Brzina dekompresije

Primeri veličine fajlova sa podacima

□ Tekst

1 strana sa 80 karaktera, 64 linije po strani, 1 byte po karakteru zahteva 80*64*1*8 = 41kbit po svakoj strani

□ Slika

24 bita po pixelu, 512 x 512 pixela po slici, zahteva 512x512x24 = 6 Mbit po slici(približno)

Primeri veličine fajlova sa podacima

□ Audio

CD kvalitet, semplovano sa 44,1 KHz, 16 bita po semplu, zahteva 44,1x16=706 kbit/s

□ Video

- Full size frame sa 1024x768 pixel/frame, 24 bit/pixel, 30 frame/s, zahteva 1024x768x24x30=566 Mbit/s
- Realnije 360x240 pixel/frame, zahteva 360x240x24x30=60 Mbit/s

Načini za kompresiju

- □ Bez gubitka informacije (lossless comp.)
 - Originalni podatak se rekonstruiše u potpunosti (rekonstrukcija je istovetna originalu)
 - Koeficijent kompresije od 2:1 to 50:1
 - Primer: Huffman-ovo kodiranje
- □ Sa gubitkom dela informacija (lossy comp.)
 - Rekonstruisani podatak nije isti sa originalom
 - Uzimaju se u obzir nesavršenosti ljudskih čula (oko, uvo)
 - Viši koeficijenti kompresije (tipično oko 100:1)

Prenos slika

- Kompresija slika
 - Kompresija bez gubitaka
 - ☐ Tehnike: DPCM, HINT, DP, BPE, MAR
 - □ Stepen kompresije: od 1.5:1 do 3:1
 - Kompresija sa gubicima
 - Treba voditi računa da se ne naruši sadržaj tj. da se ne izgubi bilo koja značajna informacija
 - □ JPEG,
 - subband coding: wavelets
 - □ ...

Formati slika

- BMP (DIB) Bitmap format (device independent bitmap)
- ☐ GIF graphics interchange format
- □ JPEG Joint Photographic Experts Group
- PNG portable network graphics
- □ TIFF tagged image file format
- □ PCX PC Paintbrush Exchange



Formati multimedijalnog sadržaja

□ Video kompresija:

- <u>ISO/IEC</u>: <u>MJPEG Motion JPEG 2000</u> <u>MPEG-1</u> <u>MPEG-2</u> <u>MPEG-4 ASP MPEG-</u>4/AVC
- <u>ITU-T</u>: <u>H.120</u> <u>H.261</u> <u>H.262</u> <u>H.263</u> <u>H.264</u>
- Ostali: AMV · AVS · Bink · Dirac · Indeo · Pixlet · RealVideo · RTVideo · SheerVideo · Smacker · Snow · Theora · VC-1 · VP6 · VP7 · VP8 · WMV

Audio kompresja

- ISO/IEC: MPEG-1 Layer III (MP3) MPEG-1 Layer II MPEG-1 Layer I AAC HE-AAC
- <u>ITU-T</u>: <u>G.711</u> <u>G.718</u> <u>G.719</u> <u>G.722</u> <u>G.722.1</u> <u>G.722.2</u> <u>G.723</u> <u>G.723.1</u> <u>G.726</u> <u>G.728</u> <u>G.729</u> <u>G.729.1</u> <u>G.729a</u>
- Ostali: AC3 · AMR · Apple Lossless · ATRAC · FLAC · iLBC · Monkey's Audio · µ-law · Musepack · Nellymoser · OptimFROG · RealAudio · RTAudio · SHN · Siren · Speex · Vorbis · WavPack · WMA · TAK

Kompresija slika

- <u>ISO/IEC/ITU-T</u>: <u>JPEG JPEG 2000 lossless JPEG JBIG JBIG2 PNG WBMP</u>
- Ostali: APNG BMP GIF ICER ILBM PCX PGF TGA TIFF JPEG XR / HD Photo

Media containers

- Opšti: 3GP · ASF · AVI · Bink · DMF · DPX · EVO · FLV · Matroska · MPEG-PS · MPEG-TS · MP4 · MXF · NUT · Ogg · Ogg Media · QuickTime · RealMedia · Smacker · RIFF · VOB
- Samo audio: <u>AIFF</u> · <u>AU</u> · <u>WAV</u>



Primeri kompresije

Originalna slika: veličina: 1,177,864 bajta odnos 1:2.2

GIF kompresija JPEG kompresija 545,463 byte Optimizovan kvalitet Optimizovana 127,246 byte odnos 1:9.3

JPEG kompresija veličina 26,141 byte odnos 1:45









Originalna slika: veličina: 1,989,536 byte odnos 1:1.7 283,557 byte

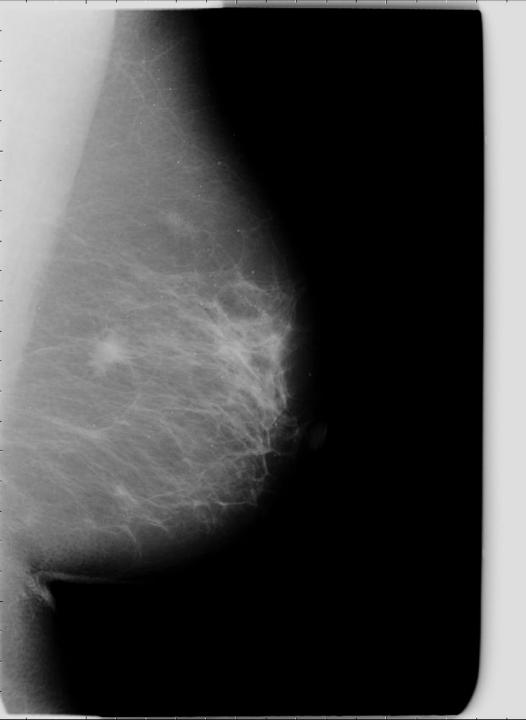
GIF kompresija JPEG kompresija 1,175,620 byte Optimizovan kvalitet odnos 1:7

JPEG kompresija Optimizovana veličina 39,690 byte odnos 1:50





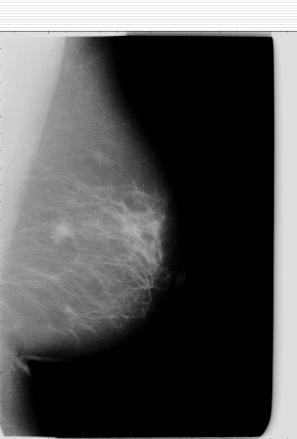




Originalna slika: Veličina: 746,786 byte

GIF kompresija JPEG kompresija 315,683 byte Optimizovan kvalitet Optimizovana odnos 1:2.4 89,200 byte odnos 1:8.4

JPEG kompresija veličina 24,783 byte odnos 1:30



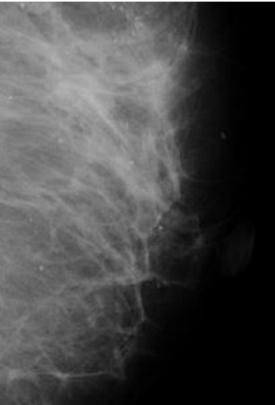


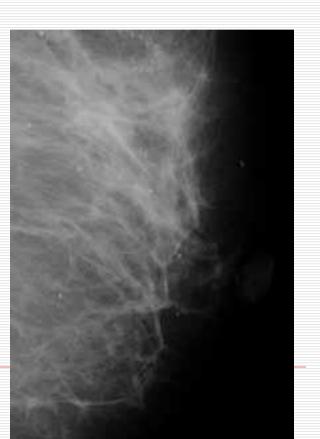


Uvećan deo prethodne slike

Originalna slika veličina: 65,589 JPEG kompresija JPEG kompresija Optimizovan kvalitetoptimizovana veličir 14,411 byte 3,731 byte odnos 1:4.6 odnos 1:17.6

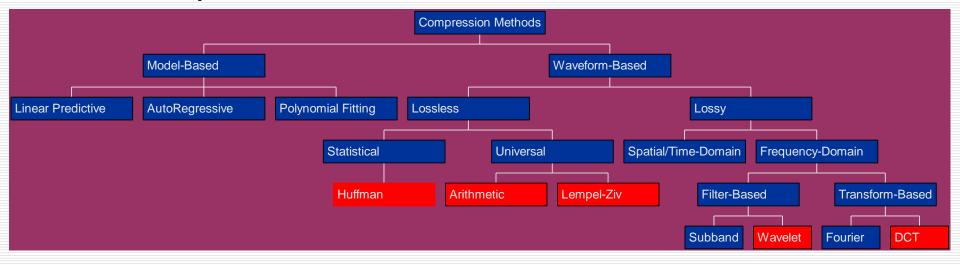






Šta se koristi kod kompresije?

- Smanjuje se količina podataka na osnovu postojeće korelacije
 - prostorne
 - vremenske
 - spektralne



Tehnike za kompresiju

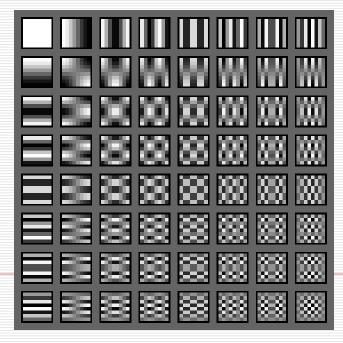
- □ RLE (Run-Length Encoding)
 - Niz karaktera koji se ponavljaju se kodiraju brojem pojavljivanja i jednim karakterom.
- □ Huffmanov kod
 - Prefiks kod koji predstavlja optimalni kod zasnovan na učestanosti pojavljivanja simbola.
- □ LZW (Lempel-Ziv-Welch)
 - Kodira niz karaktera koji se nalaze u rečniku.
- □ Aritmetičko kodovanje
 - Menja niz simbola realnim brojem.

Tehnike za kompresiju

- □ Diferencijalno kodovanje Kodiraju se razlike izmedju tekućeg i prethodnog podatka.
- Diskretna Kosinusna transformacija

Transformiše blok podataka u težinsku sumu

prostornih frekvencija.



Primer lossless algoritma

- Zamena paterna
 - ABCDEABCEEABCEE ABC sa 1, EE sa 2
 - 1DE1212
- ☐ ABCEE sa 1
 - Dobija se ABCDE11
 - U oba primera isti stepen kompresije

RL Kodovanje (run length coding)

- Zamena svih uzastopnih pojavljivanja simbola brojem ponavljanja i simbolom
- Primer: AAAABBBAABBBBBCCCCCCCDABCBAABBB BCCD
- □ Kod 4A3B2A5B8C1D1A1B1C1B2A4B2C1D
- Dugačak niz blanko znakova, vodeće nule u brojevima ili stringovima "belog" u grayscale slikama

RL kodovanje binarnih fajlova

```
28 14 9
26 18 7
23 24 4
22 26 3
20 30 1
19 7 18 7
19 5 22 5
       19 3 26 3
19 3 26 3
19 3 26 3
19 3 26 3
20 4 23 3 1
22 3 20 3 3
1 50
1 50
1 50
1 50
       1 50
1 2 46 2
50
```

Patenti

- Run length encoding of the type (length, character)
 - US Patent No: 4,586,027
 - Title: Method and system for data compression and restoration
 - Filed: 07-Aug-1984
 - Granted: 29-Apr-1986
 - Inventor: Tsukimaya et al.
 - Assignee: Hitachi

Patenti

- Run length encoding (length [<= 16], character)
 - US patent Number: 4,872,009
 - Title: Method and apparatus for data compression and restoration
 - Filed: 07-Dec-1987
 - Granted: 03-Oct-1989
 - Inventor: Tsukimaya et al.
 - Assignee: Hitachi

Kodovanje promenljive dužine

- Klasičan pristup svi znaci imaju kod iste dužine
- Ako je učestalost pojavljivanja znakova različita onda se koriste kodovi različite dužine (za frekventnije simbole kod je kraći)
- □ Primer:

Kod 1: A B C D E ...

1 2 3 4 5 ...

Primer - nastavak

- □ ABRACADABRA sa dužinom koda 5 bita 00001 00010 10010 00001 00011 00001 00100 00001
- □ Kod 2: A (0), B(1), R(01), C(10), D(11)

 1 01 0 10 0 11 0 1 01 0
- Dešifrovanje samo ako se uvedu ograničavači
- Povećanje dužine kodiranog stringa u nekim slučajevima značajno

Kodovanje bez ograničavača

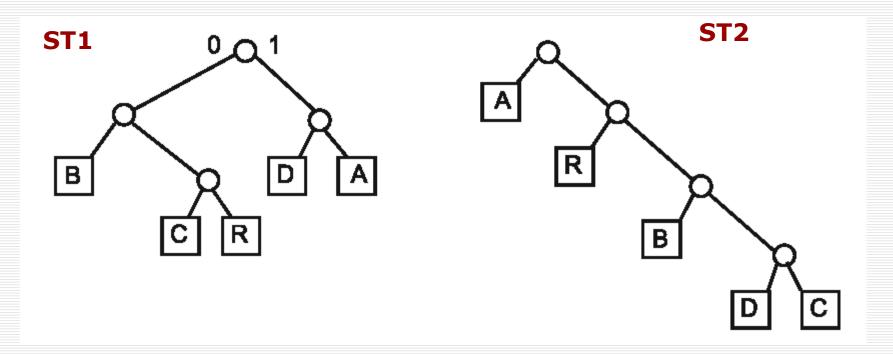
- Ideja: Kod takav da nijedna kodna reč ne može da bude prefiks druge kodne reči
- Onda nije potrebno ubacivati ograničavače
- Primer:

```
A(11), B(00), R(011), C(010) i D(10)
11 00 011 11 010 11 10 11 00 011 11
A B R A C A D A B R A
```

Korišćenje stabala

- Svako stablo sa <u>M terminala</u> može da se koristi za predstavljanje koda za string koji sadrži <u>M različitih simbola</u>
- Reč ABRACADABRA može da se kodira različitim kodovima koji mogu da se predstave pomoću stabala.
- □ 0 grana levo, 1- grana desno

Korišćenje stabala



- □ A-11, B-00, C-010, D-10, R-011
- □ A-0, B-110, C-1111, D-1110, R-10

Korišćenje stabala

- ☐ Kod po levom stablu ST1:

 1100011110101110110001111
- ☐ Kod po desnom stablu ST2:
 011010011111011100110100
- □ ST1 kod 25 bita
- □ ST2 kod 23 bita
- Reprezentacija koda pomoću stabla garantuje da nijedna kodna reč nije prefiks druge kodne reči

Osnovne ideje

- □ RL kodovanje
- Srednja entropija informacija
- □ Izvor S generiše simbole S₁ do SN
 - Entropija: $I(s_i) = log \frac{1}{p_i} = -log p_i$
 - Entropija izvora S: $H(S) = \sum_{i} p_i \log_2 p_i$
 - Srednji broj bita za kodovanje ≤ H(S) Shannon
- Diferencijalno kodovanje
 - Da bi se poboljšala raspodela verovatnoće pojavljivanja simbola

Osnovne ideje

- Pitanje: kako izabrati kod promenljive dužine koji je optimalan za odgovarajuću raspodelu verovatnoće pojavljivanja simbola?
- □ Odgovor:
 - David Huffman 1952 daje svoj algoritam

Huffmanov kod - generisanje

- □ Neka alfabet ima N simbola S₁ ... S_N
- Neka je p_i verovatnoća pojavljivanja simbola S_i
- Poredjati simbole po njihovoj verovatnoći pojavljivanja

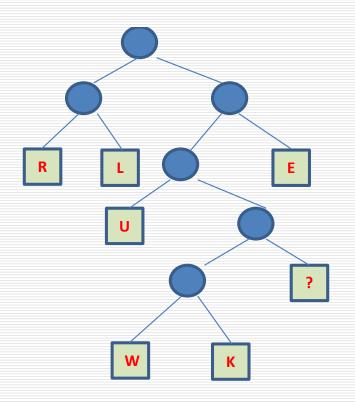
$$p_1 \ge p_2 \ge p_3 \ge ... \ge p_N$$

- \square Zameniti simbole S_{N-1} i S_N novim simbolom H_{N-1} tako da on ima verovatnoću $p_{N-1}+p_N$
- Ponoviti postupak sve dok se ne dobije jedan simbol
- Ovaj postupak generiše binarno stablo

Huffmanov kod - primer

Simbol	Verovatn oća	Kodna reč
K	0.05	10101
L	0.2	01
U	0.1	100
W	0.05	10100
E	0.3	11
R	0.2	00
?	0.1	1011

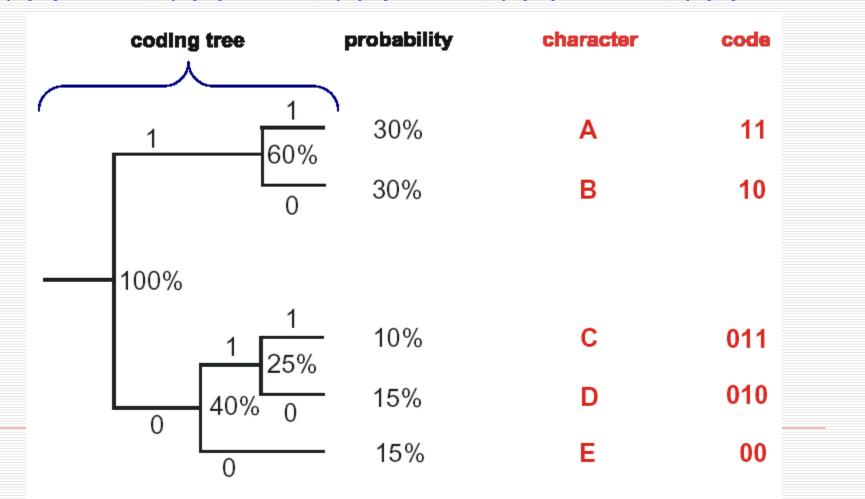
- □ Simboli se uzimaju:
 - K+W
 - {K,W}+?
 - {K,W,?}+U
 - {R,L}
 - {K,W,?,U}+E
 - {{K,W,?,U,E},{R,L}}
- Kodne reči se generišu obilaskom generisanog stabla



Simbol	Verovatn oća	Kodna reč
K	0.05	10101
L	0.2	01
U	0.1	100
W	0.05	10100
E	0.3	11
R	0.2	00
?	0.1	1011

Primer

p(A) = 0.3; p(B) = 0.3; p(C) = 0.1; p(D) = 0.15; p(E) = 0.15



Huffmanov kod – optimalnost?

- Simboli sa većom verovatnoćom su bliže korenu stabla što znači da imaju kraću dužinu kodne reči što je i cilj
- To je najbolji mogući kod za datu raspodelu verovatnoća!
- Suma verovatnoća puta dužina kodne reči je minimalna.
- Indukcijom se pokazuje da je za bilo koji drugi slučaj ova suma veća.

Osobine Huffmanovog koda

- Ulaz fiksne dužine daje izlaz promenjive dužine
- \square Srednja dužina kodne reči: $\sum l_i p_i$
- Gornja granica srednje dužine je zbir entropije izvora i maksimalne verovatnoće simbola: H(S) + p_{max}
- □ Složenost generisanja koda: O(N log N)
- Zadovoljen uslov o prefiksima tj. nijedna kodna reč nije prefiks neke druge
 - Kod obezbedjuje jednoznačno dekodiranje

Huffmanovo kodiranje

- Zasnovano na stablu
- Zasnovano na Look-up tabeli
- Kodiranje zasnovano na stablu
 - ☐ Za svaki ulazni simbol se obilazi stablo polazeći od korena dok se ne dosegne terminal koji je pridružen tom simbolu.
 - □ Na izlaz se ispisuje predjena putanja sastavljena od 0 (leva grana) i 1 (desna grana)
 - Postupak se ponavlja za svaki ulazni simbol

Huffmanovo kodiranje

Kodiranje zasnovano na Look-up tabelama

- Kreiranje look-up tabele
 - Neka najduža kodna reč ima dužinu L
 - □ Tabela ima 2^L elementa
 - □ Neka je c_i kodna reč koja odgovara simbolu s_i
 - Ako c_i ima l_i bita, obrazuj L-bitnu adresu tako da prvih l_i bita budu c_i a ostatak može da bude neka od 2^(L-l_i) kombinacija nula i jedinica.
 - □ Obrazuj 2^(L-I_i) adresa za svaki simbol s_i
 - \square Za svaki element zapamti parove (s_i, l_i)
- Proces dekodiranja
 - ☐ Učitaj L bita u bafer
 - Uzmi simbol s_k, koji ima adresu L i dužinu koda l_k
 - ☐ Izbaci I_k bita iz bafera i učitaj novih I_k bita u bafer

Primer:

- □ Iscrtati Lookup tabelu za
- \square p(A) = 0.3; p(B) = 0.3; p(C) = 0.1; p(D) = 0.15; p(E) = 0.15
 - A(11)
 - **■** B(10)
 - **■** C(011)
 - **■** D(010)
 - **■** E(00)

000	E 2
001	E 2
010	D 3
011	C 3
100	B 2
101	B 2
110	A 2
111	A 2



1100010011

Huffman-ov kod - osobine

- Dekodiranje zasnovano na look-up tabeli je brzo
- Dobar za mnoge praktične primene
- Koristi se ako je unapred poznata raspodela verovatnoća pojave simbola izvora podataka
- Varijanta: za svaki dokument najpre odredi verovatnoće pa ih dodaj uz dokument

Problemi!

- Ako su frekvence pojavljivanja simbola iste.
- Model entropije reda-0
 - Pojavljivanje simbola nije uslovljeno prethodnim pojavljivanjem nekog drugog simbola tj. nezavisni su.
 - ABCD ABCD ABCD ...
 - Model entropije reda-1 (C nakon B, B nakon A, itd.)
 - Mnogi izvori podataka imaju korelaciju između simbola npr. U engleskom jeziku: posle c često dolazi h a retko z

Pitanja

??????